

Estimación del redshift fotométrico en cuásares del SDSS mediante Random Forest: comparación entre regresión continua y clasificación por rangos.

Mateo Bustamante Moreno

1. Resumen

En este trabajo se estudia la estimación del redshift fotométrico en cuásares a partir de una base de datos extraída de *SDSS SkyServer*. Se construyó una muestra inicial de 751 178 cuásares con redshift espectroscópico confiable y, tras un proceso de depuración de valores inválidos, nulos y mediciones no físicas, se obtuvo un conjunto final de 747 661 objetos. Con esta base se evaluaron dos enfoques supervisados basados en *Random Forest*: un modelo de regresión continua para predecir directamente el redshift espectroscópico y un modelo de clasificación por rangos de redshift.

El análisis exploratorio mostró que la distribución del redshift está fuertemente concentrada entre $z \sim 1$ y $z \sim 3$, con una caída marcada en los extremos altos, y que los colores fotométricos son las variables más informativas. El modelo de regresión alcanzó un desempeño notable en entrenamiento, pero con una degradación en validación y prueba que evidencia sobreajuste moderado. El modelo de clasificación obtuvo una accuracy de prueba cercana al 76 %, con mejor desempeño en las clases intermedias y mayores dificultades en la clase de alto redshift. En conjunto, el estudio muestra que la regresión continua es el enfoque más adecuado para el objetivo científico principal, mientras que la clasificación por rangos constituye una herramienta complementaria útil para el diagnóstico del problema y el análisis de sus degeneraciones.

Palabras clave: redshift fotométrico, cuásares, Sloan Digital Sky Survey (SDSS), Random Forest, aprendizaje automático, regresión supervisada, clasificación supervisada, minería de datos astronómicos.

2. Introducción

El redshift constituye una de las magnitudes fundamentales de la astronomía extragaláctica, pues permite relacionar el desplazamiento al rojo de las líneas espectrales con la expansión del universo y, por tanto, con la distancia cosmológica de los objetos. En el caso de los cuásares, la medición espectroscópica del redshift es la referencia más confiable; sin embargo, este procedimiento requiere recursos observacionales significativos. En consecuencia, la estimación del *redshift fotométrico* se presenta como una alternativa de gran interés cuando únicamente se dispone de información multibanda obtenida a partir de imágenes.

El problema es especialmente desafiante en cuásares. A diferencia de otras poblaciones astronómicas, la relación entre color fotométrico y redshift no es simple ni aproximadamente lineal. El desplazamiento de líneas de emisión, la variación del continuo espectral y las degeneraciones entre bandas fotométricas producen regiones del espacio de parámetros donde distintos redshifts pueden presentar colores similares. En este contexto, los métodos de aprendizaje automático ofrecen una herramienta adecuada, ya que pueden capturar relaciones no lineales complejas sin imponer una forma funcional rígida.

El objetivo de este trabajo es construir y comparar dos estrategias supervisadas basadas en *Random Forest* para el estudio del redshift fotométrico de cuásares del Sloan Digital Sky Survey (SDSS): un modelo de regresión continua y un modelo de clasificación por rangos. El primero busca predecir directamente el valor de redshift espectroscópico; el segundo analiza el problema en intervalos discretos de redshift, facilitando la interpretación mediante métricas de clasificación y matriz de confusión.

3. Metodología

3.1. Fuente de datos y construcción de la muestra

La base de datos se obtuvo mediante una consulta SQL en *SDSS SkyServer*, seleccionando objetos clasificados como cuásares (`class = 'QSO'`) y con calidad espectroscópica confiable (`zWarning = 0`).

La consulta incluyó tanto información astrométrica como fotométrica: identificador del objeto, ascensión recta, declinación, redshift espectroscópico, error del redshift, magnitudes PSF en las bandas `u`, `g`, `r`, `i`, `z` y colores derivados `ug`, `gr`, `ri`, `iz`. En esta etapa se trabajó con los datos fotométricos observados, es decir, sin aplicar corrección por extinción galáctica, con el propósito de analizar el comportamiento del modelo sobre la fotometría tal como es entregada por la base de datos.

La muestra inicial estuvo compuesta por 751 178 cuásares. Posteriormente se realizó una depuración básica orientada a remover valores inválidos o no físicos. En particular, se eliminaron filas con magnitudes iguales a `-9999`, valor utilizado como bandera de ausencia de dato; se descartaron valores nulos en las variables relevantes; se eliminaron objetos con `zErr <= 0`, ya que un error negativo no es físicamente interpretable en este contexto; y se restringió el análisis a `z_spec >= 0`, ya que no hay evidencia de cuásares con redshift negativo, por tanto si aparece algún dato relacionado se puede hacer referencia a un dato faltante. Como resultado, la muestra final utilizada para modelado quedó en 747 661 objetos.

3.2. Análisis exploratorio

Antes del entrenamiento de los modelos, se realizó un análisis exploratorio de la distribución de redshift y de la relación entre las variables fotométricas y la variable objetivo. El histograma del redshift evidenció una distribución marcadamente no uniforme, con un máximo de densidad entre $z \approx 1$ y $z \approx 3$ y una disminución fuerte hacia redshifts altos. Este comportamiento es relevante porque implica un desbalance natural de la muestra, especialmente en los extremos del intervalo.




Imagen 1: Distribución de los cuásares. Cuántos cuásares hay por cada valor de redshift.

Asimismo, se estudiaron las relaciones entre los colores fotométricos `ug`, `gr`, `ri`, `iz` y `z_spec` [1]. Los diagramas de dispersión mostraron estructuras no lineales y regiones de alta superposición entre distintos valores de redshift. Entre todas las variables, los colores fotométricos resultaron ser las características con mayor poder descriptivo, en particular `ug`, `gr` y `ri`. Este resultado concuerda con la naturaleza física del problema, pues el redshift modifica la posición relativa de rasgos espectrales dentro de las bandas fotométricas.

3.3. Modelo A: regresión continua

El primer enfoque formuló el problema como una regresión supervisada. La variable objetivo fue el redshift espectroscópico `z_spec`, y las variables explicativas incluyeron las magnitudes PSF en las cinco bandas del SDSS y los cuatro colores derivados.

La base de datos se dividió en tres subconjuntos: entrenamiento, validación y prueba, en proporciones aproximadas de 70 %, 15 % y 15 %, respectivamente. La partición se realizó con estratificación por bins de redshift, con el fin de preservar la forma de la distribución original en cada subconjunto. Esta decisión es importante, ya que el problema presenta un sesgo fuerte hacia ciertos rangos de redshift, y una división aleatoria sin control podría generar subconjuntos poco representativos.

Para este modelo se utilizó un *RandomForestRegressor* como estimador base. El desempeño se evaluó mediante tres métricas: error absoluto medio (MAE), raíz del error cuadrático medio (RMSE) y coeficiente de determinación (R^2). Adicionalmente, se analizaron el diagrama de dispersión entre el redshift real y el predicho, la distribución de residuales y la importancia relativa de las variables.

3.4. Modelo B: clasificación por rangos

El segundo enfoque reformuló el problema como una clasificación multiclase. Para ello, el redshift espectroscópico se discretizó en cinco clases amplias:

- clase 0: $0 \leq z < 1$,
- clase 1: $1 \leq z < 2$,
- clase 2: $2 \leq z < 3$,
- clase 3: $3 \leq z < 4$,
- clase 4: $4 \leq z \leq 7.1$.

La elección de estos rangos respondió a dos criterios: por un lado, preservar un número suficiente de objetos por clase; por otro, respetar la distribución empírica observada en la muestra. Al igual que en el Modelo A, la división en entrenamiento, validación y prueba se hizo de manera estratificada, ahora respecto de la clase de redshift.

Se entrenó un *RandomForestClassifier* y se evaluó con accuracy, precision, recall, F1-score y matriz de confusión. Dado que la clase de alto redshift estaba significativamente subrepresentada, se probó además una variante del modelo con ponderación de clases para reducir el efecto del desbalance. Finalmente, se conservó una configuración regularizada que redujo el sobreajuste en entrenamiento sin mejorar de manera drástica la validación y la prueba, lo cual fue considerado preferible desde el punto de vista metodológico.

4. Resultados

4.1. Distribución de la muestra

El análisis del redshift confirmó una fuerte asimetría en la distribución. La mayor parte de los objetos

se concentra entre $z \sim 1$ y $z \sim 3$, mientras que los redshifts superiores a 4 constituyen una fracción muy pequeña de la muestra total. Este resultado tiene implicaciones directas sobre el aprendizaje automático: los modelos tienden a ajustarse mejor en los rangos con abundancia de datos y a degradarse en regiones poco pobladas.

La exploración de colores mostró rangos plausibles y outliers limitados. Los percentiles indicaron que la mayoría de los objetos se concentran en ventanas relativamente estrechas de color, mientras que los valores extremos son muy escasos. En términos prácticos, esto sugiere que la muestra presenta una buena base para modelado, pero también que la relación color-redshift es compleja y no perfectamente separable.

4.2. Desempeño del modelo A: regresión continua del redshift fotométrico

La primera aproximación abordó el problema como una tarea de regresión supervisada, en la cual el objetivo fue predecir directamente el redshift espectroscópico (z_{spec}) a partir de las magnitudes fotométricas en las bandas del SDSS y de los colores derivados. Para ello se utilizó un modelo *Random Forest Regressor*, evaluado mediante las métricas MAE (*Mean Absolute Error*), RMSE (*Root Mean Squared Error*) y coeficiente de determinación (R^2).

Cuadro 1: Desempeño del Modelo A.

Conjunto	MAE	RMSE	R^2
Train	0.1237	0.1972	0.9391
Validation	0.3322	0.5256	0.5672
Test	0.3337	0.5285	0.5622

Los resultados muestran un excelente ajuste sobre el conjunto de entrenamiento, con un coeficiente de determinación cercano a 0.94. Sin embargo, el desempeño disminuye de manera apreciable en los conjuntos de validación y prueba, donde el valor de R^2 se reduce hasta aproximadamente 0.56. Esta diferencia evidencia la existencia de sobreajuste moderado, aunque la gran similitud entre validación y prueba indica que el comportamiento observado es estable y representa adecuadamente la capacidad

real de generalización del modelo.




Imagen 2: Diagrama de dispersión entre redshift espectroscópico y redshift predicho.




Imagen 3: Como se distribuye la diferencia entre el redshift espectroscópico y redshift predicho.




Imagen 4: Variables espectroscópicas que fueron más influyentes en el modelo.

Las figuras muestran el comportamiento detallado del modelo. El diagrama de dispersión entre el redshift real y el predicho presenta una tendencia diagonal claramente definida, indicando que el modelo ha logrado capturar una relación física real entre la fotometría observada y el redshift. No obstante, también se aprecia una dispersión significativa alrededor de la diagonal ideal, particularmente en las regiones de redshift intermedio y alto.

Este comportamiento es consistente con la naturaleza de los cuásares. A diferencia de otros objetos astronómicos, la relación color-redshift en cuásares presenta degeneraciones importantes debido al desplazamiento progresivo de líneas de emisión y absorción a través de los filtros fotométricos. Como consecuencia, distintos objetos pueden presentar colores similares aun cuando sus redshifts sean diferentes.

La distribución de residuales se encuentra centrada aproximadamente en cero, lo que indica la ausencia de un sesgo sistemático fuerte en la predicción. Sin embargo, la presencia de colas relativamente extensas revela la existencia de objetos para los cuales el error cometido por el modelo es considerable. Estos casos corresponden principalmente a regiones donde la relación fotometría-redshift es particularmente ambigua.

El análisis de importancia de variables muestra que los colores fotométricos dominan claramente la capacidad predictiva del modelo. La variable **ug** aparece como la característica más importante, seguida por **ri** y **gr**. Entre las magnitudes individuales, **Mag. u** es la que presenta mayor relevancia. Este resultado es consistente con la física del problema, ya que el redshift afecta principalmente la distribución relativa del flujo entre bandas y no tanto las magnitudes individuales consideradas de forma aislada.

4.3. Desempeño del modelo B: clasificación por rangos de redshift

El segundo enfoque reformuló el problema como una tarea de clasificación supervisada. En lugar de predecir directamente el valor de redshift, se definieron cinco clases amplias:

- Clase 0: $0 \leq z < 1$

- Clase 1: $1 \leq z < 2$
- Clase 2: $2 \leq z < 3$
- Clase 3: $3 \leq z < 4$
- Clase 4: $4 \leq z \leq 7.1$

Esta discretización permitió estudiar el problema desde una perspectiva más robusta e interpretable, especialmente mediante el uso de matrices de confusión y métricas de clasificación.

===== Train =====				
Accuracy: 0.94294				
Classification report:				
	precision	recall	f1-score	support
0	0.93325	0.92165	0.92742	108072
1	0.96338	0.95271	0.95802	231928
2	0.93606	0.93365	0.93485	155645
3	0.85626	0.99592	0.92082	24739
4	0.91546	1.00000	0.95587	2978
accuracy			0.94294	523362
macro avg	0.92088	0.96079	0.93939	523362
weighted avg	0.94369	0.94294	0.94304	523362
===== Validation =====				
Accuracy: 0.76323				
Classification report:				
	precision	recall	f1-score	support
0	0.64623	0.60797	0.62652	23159
1	0.83215	0.85139	0.84166	49699
2	0.74927	0.74268	0.74596	33352
3	0.69559	0.78627	0.73816	5301
4	0.57359	0.41536	0.48182	638
accuracy			0.76323	112149
macro avg	0.69937	0.68073	0.68682	112149
weighted avg	0.76118	0.76323	0.76183	112149
===== Test =====				
Accuracy: 0.76159				
Classification report:				
	precision	recall	f1-score	support
0	0.64357	0.60925	0.62594	23158
1	0.83186	0.84960	0.84063	49700
2	0.74701	0.73975	0.74336	33353
3	0.69685	0.78400	0.73786	5301
4	0.52532	0.39028	0.44784	638
accuracy			0.76159	112150
macro avg	0.68892	0.67458	0.67913	112150
weighted avg	0.75962	0.76159	0.76028	112150

Imagen 5: Métricas de entrenamiento, validación y prueba.




Imagen 6: Matriz de confusión, están todos los cuásares clasificados como verdaderos, falsos positivos o falsos negativos.




Imagen 7: Matriz de confusión normalizada, están todos los cuásares clasificados como verdaderos, falsos positivos o falsos negativos.




Imagen 8: Variables espectroscópicas que fueron más influyentes en el modelo.

La versión final seleccionada del clasificador corresponde a una variante regularizada del Random Forest. Durante el desarrollo del trabajo se exploraron diferentes configuraciones modificando parámetros como `n_estimators`, `max_depth`, `min_samples_leaf`, `max_features` y `class_weight`. El objetivo de estas pruebas fue controlar el sobreajuste observado en primeras versiones del modelo (hubo una ocasión con un train de 100 %) y evaluar si una mayor regularización producía mejoras en validación y prueba.

La configuración finalmente adoptada logró reducir el desempeño artificialmente perfecto observado inicialmente en entrenamiento, manteniendo prácticamente inalteradas las métricas de validación y prueba. Desde un punto de vista metodológico, esta solución resulta preferible porque produce un modelo más equilibrado y con menor riesgo de memorización.

Los resultados finales muestran una *accuracy* cercana al 76 % sobre el conjunto de prueba. Aunque este valor es inferior al observado en entrenamiento, se mantiene consistente con el obtenido en validación, lo que indica una capacidad de generalización razonablemente estable.

El *classification report* muestra que las clases intermedias presentan el mejor desempeño. Particularmente, la clase correspondiente al intervalo $1 \leq z < 2$ alcanza los valores más altos de precisión, recall y F1-score. En contraste, la clase de alto redshift ($4 \leq z \leq 7.1$) constituye el principal desafío para el modelo.

La matriz de confusión presentada en la Figura 6 permite visualizar con claridad el comportamiento del clasificador. La mayor parte de las predicciones correctas se concentra sobre la diagonal principal, lo que demuestra que el modelo logra distinguir adecuadamente los grandes rangos de redshift. Asimismo, los errores observados ocurren principalmente entre clases adyacentes.

Este resultado es particularmente relevante desde una perspectiva física. El hecho de que el clasifica-

dor confunda objetos entre clases vecinas y no entre clases alejadas indica que el modelo está capturando la estructura general de la relación color-redshift. En otras palabras, los errores cometidos son razonables desde el punto de vista astronómico.

La matriz de confusión normalizada refuerza esta interpretación. Se observa que las clases centrales son recuperadas con alta eficiencia, mientras que la clase de alto redshift presenta una tasa de recuperación considerablemente menor. Este comportamiento puede explicarse por dos factores principales: la baja representación estadística de dicha clase en la muestra y la complejidad intrínseca de los cuásares de alto redshift.

Finalmente, el análisis de importancia de variables reproduce la tendencia observada en el Modelo A. Los colores `ug`, `gr` y `ri` aparecen nuevamente como las características más relevantes, confirmando que la información cromática constituye la principal fuente de información para estimar el redshift fotométrico de cuásares.

5. Discusión

La comparación entre ambos modelos permite extraer conclusiones metodológicas y físicas relevantes. El Modelo A responde de manera directa a la pregunta científica principal, ya que entrega una estimación continua del redshift. En astronomía, esta continuidad es valiosa porque permite cuantificar errores absolutos, sesgos sistemáticos y dispersión en función del redshift real. No obstante, la relación entre fotometría y redshift en cuásares es fuertemente no lineal y presenta degeneraciones notables, lo que explica la caída del rendimiento al pasar de entrenamiento a validación y prueba.

El Modelo B, por su parte, simplifica el problema al convertirlo en una tarea de clasificación discreta. Este enfoque es menos preciso desde el punto de vista físico, ya que descarta la información fina del valor continuo de redshift, pero resulta más robusto y más fácil de interpretar. La matriz de confusión hace evidente dónde se concentran los errores, permitiendo identificar las zonas del espacio de redshift donde el problema es más ambiguo. Además, la clasificación por rangos es particularmente útil cuando

se desea una preselección rápida de objetos o una segmentación preliminar en grandes catálogos.

Desde una perspectiva científica, el Modelo A es el más adecuado como resultado principal, porque la variable de interés es continua. Sin embargo, el Modelo B aporta valor como análisis complementario, ya que ayuda a entender el comportamiento del problema y a diagnosticar las regiones donde la regresión enfrenta más dificultades. En este sentido, ambos enfoques son compatibles y no deben interpretarse como mutuamente excluyentes, sino como dos vistas complementarias de la misma relación fotometría-redshift.

El trabajo también permite señalar algunas líneas de mejora. Una primera extensión natural consiste en incorporar errores fotométricos, extinción galáctica y otros parámetros de calidad observacional. Una segunda línea sería probar otros algoritmos de ensamble o modelos de boosting, que en algunos contextos ofrecen mejor rendimiento que Random Forest. Una tercera posibilidad es el uso de enfoques jerárquicos, en los que primero se clasifique el objeto en un rango amplio y luego se refine la predicción con un regresor especializado.

En cuanto a la transferibilidad de la metodología, el mismo esquema podría aplicarse a otros problemas astronómicos, como redshift fotométrico de galaxias, clasificación de estrellas variables, separación estrella-galaxia-cuásar o clasificación de supernovas. Una idea que se tenía pensada en un inicio era realizarlo con GRBs (*Gamma-Ray Bursts*), una adaptación sería conceptualmente posible, aunque mucho más desafiante debido al número reducido de eventos con redshift conocido, la heterogeneidad de los datos y la incompletitud observacional. Para GRB, un enfoque por rangos o jerárquico probablemente sería más razonable en una primera etapa que una regresión continua directa.

6. Conclusiones

- Se construyó una muestra amplia y consistente de cuásares del SDSS, partiendo de 751 178 objetos y culminando en 747 661 tras un proceso de limpieza de valores inválidos y no físicos.

- El análisis exploratorio confirmó que la distribución de redshift es fuertemente no uniforme, con una concentración principal entre $z \sim 1$ y $z \sim 3$, lo cual condiciona el aprendizaje y explica parte del desbalance observado.
- Los colores fotométricos resultaron ser las variables más informativas para ambos modelos, especialmente **ug**, **gr** y **ri**, lo que coincide con la física del desplazamiento espectral en cuásares.
- El Modelo A, formulado como regresión continua, es el más adecuado para el objetivo científico principal, ya que estima directamente el redshift fotométrico. Su principal limitación es un sobreajuste moderado y una caída de desempeño fuera del entrenamiento.
- El Modelo B, basado en clasificación por rangos, mostró un desempeño global razonable y una interpretación mucho más clara del error mediante matriz de confusión, aunque perdió información continua y sufrió especialmente en la clase de alto redshift.
- La similitud entre validación y prueba en ambos modelos sugiere que los resultados obtenidos son estables y representativos del comportamiento real de los clasificadores/regresores sobre datos no vistos.
- En el Modelo B, los errores se concentraron principalmente entre clases vecinas, lo que es coherente con la continuidad física del problema y con las degeneraciones esperadas en fotometría de cuásares.
- La regularización de la versión final del Modelo B redujo el sobreajuste aparente sin alterar sustancialmente el rendimiento fuera de entrenamiento, lo cual resulta metodológicamente preferible a una solución que simplemente maximice el ajuste en train.
- Como línea futura, se recomienda incorporar errores fotométricos, extinción galáctica, variables de calidad y estrategias de balanceo o enfoques jerárquicos para mejorar la representación de los rangos de redshift menos poblados.

- La metodología desarrollada es transferible a otros problemas de astronomía observacional, incluyendo redshift fotométrico de galaxias, clasificación de supernovas, estrellas variables y, con mayores dificultades, estimación de parámetros o redshift en GRB.

Referencias

- [1] [Colab del proyecto](#)
- [2] [Página del curso](#)
- [3] Pedregosa, F., et al. *Scikit-learn: Machine Learning in Python*. Documentación oficial
- [4] Sloan Digital Sky Survey (SDSS). SkyServer y consulta de catálogos espectroscópicos y fotométricos.